

## DATA SCIENCE

Projet : Traitement du Langage Naturel & Deep Learning

# Projet de groupe numéro 2

## Analyse de sentiment des tweets de compagnies aériennes

*De la donnée brute au modèle déployé : NLP, Deep Learning*

|                          |                                                                                                                  |
|--------------------------|------------------------------------------------------------------------------------------------------------------|
| <b>Intitulé</b>          | Classification de sentiment (négatif / neutre / positif) sur des tweets réels adressés à 6 compagnies aériennes. |
| <b>Jeu de données</b>    | Tweets.csv — 14 640 tweets annotés (US Airline Sentiment).                                                       |
| <b>Format de travail</b> | Trinôme — 3 personnes par projet.                                                                                |
| <b>Durée</b>             | 3 semaines.                                                                                                      |
| <b>Évaluation</b>        | Soutenance orale avec démonstration live                                                                         |
| <b>Mots-clés</b>         | TF-IDF · Word2Vec · BERT(opt) · ANN · CNN · LSTM · Attention · Déploiement                                       |

## 1. Contexte et enjeu business

Vous intégrez la **cellule Data Science d'une plateforme de social listening** qui accompagne plusieurs compagnies aériennes. Chaque jour, des milliers de voyageurs s'expriment sur les réseaux sociaux : retards, bagages perdus, qualité du service, mais aussi compliments. Noyés dans ce flux, les signaux faibles — un client mécontent sur le point de partir à la concurrence, une panne qui dégénère en bad buzz — passent inaperçus s'ils ne sont pas détectés automatiquement et en temps réel.

Votre client souhaite un système capable de **classer automatiquement le sentiment** de chaque tweet (négatif, neutre, positif) afin de prioriser les réponses du service client, mesurer la satisfaction par compagnie, et alerter en cas de pic de mécontentement.

### 1.1 Pourquoi c'est un vrai problème business

- Voix du client à grande échelle — impossible de lire manuellement des milliers de messages ; l'automatisation est la seule option viable.
- Priorisation du service client — un tweet négatif d'un client influent (fort taux de retweet) doit remonter en priorité.
- Réputation de marque — détecter tôt une montée de négativité permet d'agir avant la crise médiatique.
- Rétention — l'insatisfaction exprimée publiquement est un signal avancé de churn.

### 1.2 Ce que disent déjà les données

Une exploration rapide du jeu de données fournit des repères chiffrés qui cadrent la problématique :

- Déséquilibre marqué —  $\approx 63\%$  des tweets sont négatifs,  $21\%$  neutres,  $16\%$  positifs. La voix qui s'exprime est d'abord celle du mécontentement.
- Causes d'insatisfaction — les principaux motifs négatifs sont le service client ( $\approx 2\,900$  cas), les vols en retard ( $\approx 1\,665$ ), les annulations ( $\approx 850$ ) et les bagages perdus ( $\approx 720$ ).
- Fiabilité des annotations — la confiance moyenne des étiquettes est de  $0,90$ , mais certaines sont incertaines : un point à intégrer dans l'analyse.

Problématique à formuler par le groupe

À partir de ce contexte, votre trinôme devra énoncer une problématique claire et 2 à 3 questions business mesurables (ex. « quelle compagnie génère le plus d'insatisfaction et sur quels motifs ? »), puis définir les indicateurs de réussite du modèle (métriques techniques ET valeur métier).

## 2. Objectifs pédagogiques et compétences visées

Ce projet couvre l'intégralité de la chaîne de valeur d'un projet NLP moderne. À l'issue, vous devez maîtriser :

### Compétences techniques

- Préparation de texte — nettoyage, tokenisation, gestion du bruit propre aux réseaux sociaux.
- Représentations vectorielles — de la plus simple (TF-IDF) à la plus avancée (BERT), en passant par Word2Vec.
- Modélisation profonde — ANN, CNN, LSTM et mécanismes d'attention.
- Évaluation rigoureuse — métriques adaptées au déséquilibre, validation, analyse d'erreurs, interprétabilité.

### Compétences transversales

- Traduction business ↔ technique — relier chaque choix de modèle à un objectif métier.
- Travail en équipe — organisation, gestion de version (Git), répartition des rôles.
- Communication — rapport clair et soutenance convaincante avec démonstration.

### 3. Présentation du jeu de données

Le fichier **Tweets.csv** contient 14 640 tweets collectés en février 2015, adressés à six compagnies (United, US Airways, American, Southwest, Delta, Virgin America). Chaque tweet a été annoté manuellement. Colonnes principales :

| Colonne                       | Description                     | Usage projet                         |
|-------------------------------|---------------------------------|--------------------------------------|
| text                          | Texte brut du tweet             | Variable d'entrée (X)                |
| airline_sentiment             | négatif / neutre / positif      | Cible à prédire (y)                  |
| airline_sentiment_confidence  | Confiance de l'annotation (0–1) | Filtrage / pondération (option)      |
| negativereason                | Motif du mécontentement         | Analyse business / multi-tâches      |
| airline                       | Compagnie visée                 | Segmentation, analyse comparative    |
| retweet_count                 | Nombre de retweets              | Pondération de l'influence (option)  |
| tweet_created, tweet_location | Horodatage, localisation        | Analyses temporelles / géographiques |

#### 3.1 Défis à anticiper

- Classes déséquilibrées — le négatif domine ; l'exactitude brute (accuracy) est trompeuse. Privilégiez le F1-macro.
- Texte bruité — mentions @, hashtags, URLs, emojis, fautes, abréviations propres à Twitter.
- Classe « neutre » ambiguë — souvent la plus difficile à séparer ; analysez-la spécifiquement.
- Étiquettes imparfaites — certaines annotations ont une faible confiance ; décidez d'une stratégie (garder, filtrer, pondérer) et justifiez-la.

### 4. Travail demandé (cahier des charges)

Le projet est découpé en lots. Tous sont obligatoires (sauf mention « bonus »). La richesse de la comparaison entre représentations et architectures est au cœur de l'évaluation.

#### Lot 0 — Cadrage business et problématique

- Formuler la problématique, les questions business et les KPIs de succès (cf. section 1).
- Définir le protocole d'évaluation AVANT toute modélisation (métrique principale, jeu de test figé, méthode de validation).

#### Lot 1 — Exploration et préparation des données

- **EDA** — distribution des classes, volumétrie par compagnie, motifs de plainte, longueur des tweets, nuage de mots par sentiment ; au moins 4 visualisations commentées.
- **Nettoyage** — pipeline reproductible (minuscules, gestion des @mentions, #hashtags, URLs, ponctuation, emojis). Justifier chaque choix.
- **Découpage** — train / validation / test stratifié et figé (même split pour tous les modèles, pour une comparaison équitable).
- **Stratégie de déséquilibre** — choisir et justifier (rééquilibrage, class weights, ou métriques robustes).

## Lot 2 — Représentations du texte (embeddings)

Implémenter et comparer les trois familles de représentation :

- **TF-IDF** — vectorisation fréquentielle (référence simple et explicable).
- **Word2Vec** — embeddings denses entraînés sur le corpus (ou pré-entraînés) ; explorer les voisins sémantiques pour valider la qualité.
- **BERT OPTIONNELLE** — embeddings contextuels via un modèle pré-entraîné (ex. famille BERT/DistilBERT, ou CamemBERT si extension au français) — en extraction de features et/ou fine-tuning.

Exigence clé — la matrice de comparaison

Vous devez croiser représentations × architectures et présenter les résultats dans un tableau unique. Toutes les combinaisons ne sont pas requises, mais le tableau doit permettre de répondre à : « quel embedding apporte le plus, et pour quel modèle ? »

## Lot 3 — Modélisation

Construire une progression du plus simple au plus avancé. Minimum attendu :

1. **Référence** — régression logistique ou réseau de neurones simple (ANN) sur TF-IDF.
2. **CNN** — réseau convolutif 1D (détection de n-grammes) sur embeddings.
3. **LSTM** — réseau récurrent pour la dépendance séquentielle.
4. **Attention** — mécanisme d'attention ou fine-tuning d'un modèle de type BERT.

## Lot 4 — Évaluation et comparaison

- Métriques — accuracy, précision/rappel/F1 par classe, F1-macro, matrice de confusion pour chaque modèle.
- Comparaison — tableau de synthèse + courbes d'apprentissage ; discuter performance vs complexité vs coût de calcul.
- Analyse d'erreurs — examiner des cas mal classés (notamment le neutre et les tweets ambigus / ironiques).
- Interprétabilité — visualiser les poids d'attention ou les mots les plus influents ; ouvrir la « boîte noire ».

## Lot 5 — Déploiement et MLOps

- **Application de démonstration** — interface simple (Streamlit) permettant de saisir un tweet et de visualiser la prédiction.

# 5. Livrables attendus

| Livrable      | Attendu     | Format |
|---------------|-------------|--------|
| Dépôt de code | Notebooks   | PDF    |
| Rapport       | optionnelle |        |

## 6. Organisation en trinôme

Chaque membre pilote un axe mais tous doivent comprendre l'ensemble (toute personne peut être interrogée sur n'importe quelle partie en soutenance). Répartition suggérée :

| Rôle                      | Responsabilité principale                        | Contribue aussi à |
|---------------------------|--------------------------------------------------|-------------------|
| Data / EDA & embeddings   | Nettoyage, exploration, TF-IDF / Word2Vec / BERT | Analyse d'erreurs |
| Modélisation & évaluation | ANN, CNN, LSTM, Attention, comparaison           | Interprétabilité  |

## 7. Planning indicatif sur 3 semaines

| Semaine   | Objectifs                                                                                                  | Jalon / livrable intermédiaire                                |
|-----------|------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------|
| Semaine 1 | Cadrage business, EDA complète, pipeline de nettoyage, baseline TF-IDF + ANN, protocole d'évaluation figé. | Note de cadrage + baseline qui tourne de bout en bout.        |
| Semaine 2 | Word2Vec et BERT, modèles CNN / LSTM / Attention, comparaison et analyse d'erreurs.                        | Tableau de comparaison complet + meilleur modèle sélectionné. |
| Semaine 3 | Déploiement et soutenance.                                                                                 |                                                               |

### Conseil de pilotage

Visez une baseline complète de bout en bout dès la première semaine (données → modèle simple → évaluation). Il vaut mieux une chaîne entière modeste qu'un modèle sophistiqué jamais terminé. On améliore ensuite par itérations.

## 8. Modalités de soutenance

- **Durée** ≈ 10-15 minutes de présentation + 10 minutes de questions ou plus